

海南大学计算机科学与技术学院

计算机综合课程设计报告

基于 Spring Boot 与文本相似度算法的实验报告

查重系统设计实现

班 级： 计算机科学与技术 2023 级

姓 名： （请填写）

学 号： （请填写）

组 员： 无

指导老师： （请填写）

完成日期： 2026 年 6 月

摘 要

随着高校实验教学和课程实践规模不断扩大，实验报告成为评价学生实践能力和课程学习效果的重要依据。传统人工检查方式在面对同一实验任务下的大批量报告时效率较低，且难以及时发现大段复制、模板套用和局部改写等问题。针对这一场景，本文设计并实现了一套基于 Spring Boot 与文本相似度算法的实验报告查重系统。系统采用前后端分离架构，后端基于 Spring Boot、MyBatis-Plus 和 MySQL 实现用户认证、课程管理、班级管理、实验任务管理、报告上传、文本解析、查重计算和结果导出等功能，前端基于 Vue 3、Element Plus 和 ECharts 实现后台管理界面、统计看板和查重结果展示。在算法方面，系统支持 txt、docx 和 pdf 报告文本提取，对文本进行清洗、轻量级中文二元词条切分和停用词过滤，并以同一实验任务下的全部已解析报告作为语料集合计算 TF-IDF 权重。系统通过余弦相似度衡量报告向量之间的相似程度，同时引入 SimHash 文本指纹方法计算近重复文本相似度，最终按照加权融合方式得到综合相似度，并划分正常、低风险、中风险和高风险等级。系统还提供相似句子展示、统计图表、CSV 结果导出和多班级多任务演示数据，能够为教师批量复核实验报告提供可量化、可解释的辅助依据。测试结果表明，系统主流程完整，能够完成从任务创建、报告上传、文本解析、发起查重到结果展示的闭环操作，满足课程设计预期目标。

关键词：实验报告查重；文本相似度；TF-IDF；余弦相似度；SimHash

Abstract

With the expansion of experimental teaching and practical courses in universities, experimental reports have become important materials for evaluating students' practical ability and learning outcomes. Manual review is inefficient when teachers need to inspect a large number of reports under the same experimental task, and it is difficult to identify large-scale copying, template reuse and partial rewriting in time. To address this problem, this paper designs and implements an experimental report plagiarism checking system based on Spring Boot and text similarity algorithms. The system adopts a front-end and back-end separated architecture. The back end is built with Spring Boot, MyBatis-Plus and MySQL, implementing user authentication, course management, class management, experiment task management, report upload, text extraction, similarity calculation and result export. The front end is built with Vue 3, Element Plus and ECharts, providing management pages, dashboards and result visualization. In terms of algorithms, the system extracts text from txt, docx and pdf files, performs text cleaning, lightweight Chinese bigram tokenization and stop-word filtering, and calculates TF-IDF weights based on all parsed reports under the same task. Cosine similarity is used to measure vector similarity, while SimHash is introduced to evaluate near-duplicate text fingerprints. The final similarity score is obtained through weighted fusion and mapped to normal, low-risk, medium-risk and high-risk levels. The system also provides similar sentence display, statistical charts, CSV export and multi-class demonstration data, offering quantitative and interpretable support for teachers. Test results show that the system can complete the full workflow from task creation, report upload and text parsing to plagiarism checking and result display, meeting the expected objectives of the course project.

Keywords: Experimental report checking; Text similarity; TF-IDF; Cosine similarity; SimHash

目 录

提示：打开 Word 后如目录页码未自动显示，请右键目录区域选择“更新域”。

1 绪论

1.1 研究背景及意义

随着高校实验教学、课程设计和综合实践教学规模不断扩大，实验报告已经成为记录学生实践过程、反映课程理解程度和评价动手能力的重要材料。以计算机专业课程为例，一门课程往往包含多个实验任务，每个班级会集中提交数十份甚至上百份报告。教师在批阅报告时，不仅需要关注实验过程、结果分析和格式规范，还需要判断报告内容是否存在大段复制、简单改写、模板套用或网络资料拼接等情况。传统人工检查方式依赖教师经验，面对批量报告时效率较低，难以及时定位疑似重复内容。

通用论文查重系统通常面向毕业论文、期刊论文等长文本，使用成本较高，且不一定适合实验报告这种篇幅较短、结构相对固定、按课程任务提交的教学场景。因此，设计一套面向高校实验教学的轻量级实验报告查重系统具有实际意义。该系统不直接判定学生是否抄袭，而是通过相似度、风险等级和相似句子等信息，为教师提供可量化、可复核的辅助依据。

从课程设计角度看，本课题综合运用了 Web 后端开发、前端交互设计、数据库建模、文件解析、文本预处理和相似度算法等知识，能够体现计算机专业课程综合实践的特点。系统围绕课程、班级、实验任务、报告文件和查重结果形成完整业务链路，相比单独实现一个文本相似度计算程序，更符合实际教学管理需求。

1.2 国内外研究现状

文本相似度计算是自然语言处理、信息检索和文档管理领域的重要研究内容。传统方法主要包括词袋模型、n-gram、Jaccard 相似度、TF-IDF、余弦相似度和局部敏感哈希等。这类方法实现成本较低、计算效率较高、结果解释性较强，适合中小规模教学系统中的近重复文本检测。

近年来，文本相似度研究逐渐从统计特征扩展到语义特征和深度学习模型。基于 Transformer、句向量和预训练语言模型的方法在语义匹配和改写识别方面具有优势，但模型部署、算力消耗和数据依赖较高。结合课程

设计周期和系统部署成本，本系统选择 TF-IDF、余弦相似度和 SimHash 作为主要算法，兼顾可实现性、运行效率和可解释性。

对于中文实验报告而言，文本处理还会受到中文分词、专业术语、固定实验模板、代码片段和实验步骤相似等因素影响。为降低实现复杂度，系统采用轻量级中文二元词条切分方法，并结合停用词过滤完成文本预处理。该方法不能替代成熟语义模型，但能够在课程设计范围内满足实验报告近重复检测需求。

1.3 本文主要研究内容

本文围绕“基于 Spring Boot 与文本相似度算法的实验报告查重系统设计与实现”展开，主要完成以下工作：第一，分析高校实验报告查重场景的业务需求，确定管理员、教师和学生三类角色及其功能边界；第二，设计基于 Spring Boot、Vue 和 MySQL 的前后端分离系统架构；第三，建立课程、班级、实验任务、报告文件、查重任务、查重结果和相似句子等核心数据表；第四，实现 txt、docx、pdf 文本解析和上传内容基础检测；第五，设计并实现基于 TF-IDF 余弦相似度与 SimHash 的组合查重算法；第六，完成查重结果列表、相似句详情、统计图表和 CSV 导出等功能；第七，设计多班级、多学生、多任务演示数据并进行系统测试。

1.4 论文组织结构

全文共分为九章。第 1 章介绍研究背景、意义、研究现状和本文主要工作；第 2 章介绍系统相关理论基础与关键技术；第 3 章进行需求分析；第 4 章给出系统总体设计；第 5 章说明数据库设计；第 6 章介绍查重算法设计与实现；第 7 章介绍系统主要功能实现；第 8 章进行系统测试与结果分析；第 9 章总结全文并提出后续展望。

2 理论基础与关键技术

2.1 B/S 架构与前后端分离

B/S 架构即 Browser/Server 架构，用户通过浏览器访问系统，主要业务逻辑部署在服务器端。该架构不需要在用户端安装专门客户端，便于系统部署、升级和维护。实验报告查重系统面向教师和学生使用，采用 B/S

架构能够降低使用门槛，用户只需通过浏览器即可完成登录、任务查看、报告上传和结果查看等操作。

本系统采用前后端分离模式，前端负责页面展示、交互控制和图表渲染，后端提供 REST API、业务逻辑和数据持久化。前端使用 Axios 调用后端接口，后端统一返回 JSON 数据。前后端分离使系统结构更加清晰，也便于后续扩展移动端或其他客户端。

2.2 Spring Boot 与 MyBatis-Plus

Spring Boot 是基于 Spring 生态的快速开发框架，能够通过自动配置简化 Web 应用开发。本系统后端使用 Spring Boot 构建 REST API，并通过 Controller、Service、Mapper 分层组织代码。Controller 层负责接收请求，Service 层处理业务逻辑，Mapper 层负责数据库访问。

MyBatis-Plus 是 MyBatis 的增强工具，提供常用 CRUD、条件构造器和分页等能力。本系统使用 MyBatis-Plus 操作 MySQL 数据库，可以减少重复 SQL 编写，提高开发效率。系统中的用户、课程、班级、实验任务、报告文件和查重结果均通过实体类和 Mapper 完成持久化。

2.3 Vue、Element Plus 与 ECharts

Vue 3 是渐进式 JavaScript 框架，适合构建响应式单页应用。Element Plus 提供表格、表单、对话框、菜单等后台管理常用组件，可以提高前端开发效率。ECharts 是常用的数据可视化库，本系统使用它展示风险等级占比、核心数据统计、相似度区间分布和查重任务趋势等图表。

系统前端采用单页后台管理结构，通过侧边栏菜单组织首页看板、用户管理、课程管理、班级管理、实验任务、报告上传、查重结果和统计分析等功能。虽然当前主要功能集中在一个视图文件中，但从用户使用角度已经形成清晰的模块划分。

2.4 文本相似度算法基础

TF-IDF 是信息检索中常用的词项权重计算方法，用于衡量词项在文档集合中的重要程度。词频 TF 反映词项在当前文档中的出现频率，逆文档

频率 IDF 反映词项在整个文档集合中的区分能力。对于实验报告查重场景，若某些词语只在少数报告中频繁出现，则这些词语对区分文本更有价值。

余弦相似度通过计算两个向量夹角的余弦值衡量相似程度，取值越接近 1 表示两个文本向量越接近。SimHash 是一种文本指纹算法，可以将文本特征映射为固定长度的二进制指纹，再通过汉明距离判断文本指纹的接近程度。余弦相似度适合衡量词项重合程度，SimHash 适合快速判断近重复文本，二者结合能够提高结果的稳定性和解释性。

3 需求分析

3.1 用户角色分析

系统主要面向管理员、教师和学生三类用户。管理员负责基础数据维护；教师负责实验任务、报告上传、查重任务和结果分析；学生负责查看实验任务并提交自己的实验报告。不同角色具有不同功能边界，系统通过 JWT 和角色字段进行识别。

3.2 功能需求分析

系统功能需求可以分为登录认证、基础数据管理、实验任务管理、报告上传与解析、查重计算、结果展示、统计分析和结果导出等模块。登录认证模块负责用户身份验证和 Token 生成；基础数据管理模块维护用户、课程、班级和学生班级关系；实验任务管理模块用于创建和维护课程实验任务；报告上传模块支持单文件上传和批量上传；查重模块对同一任务下报告进行两两比较；结果模块展示相似度、风险等级和相似句；统计模块展示整体数据和风险分布。

报告上传还需要完成基础内容检测，包括文件是否为空、文件大小是否超过限制、文件类型是否合法、文本是否能够提取、字数统计、句子数量统计以及文本过短提示。该检测结果显示在报告列表中，便于教师了解上传文件质量。

3.3 非功能需求分析

在安全性方面，系统需要实现基础登录认证、角色权限控制、上传文件类型校验和文件大小限制；在可维护性方面，后端应采用分层结构，前

端应按功能模块组织页面逻辑；在可扩展性方面，系统应支持后续增加更多文件格式、分词算法、历史报告库和 Word/PDF 报告导出；在易用性方面，系统应提供清晰的后台菜单、直观的风险标签和统计图表。

角色	主要职责	核心功能
管理员	维护系统基础数据	用户管理、课程管理、班级管理、班级学生分配、系统看板
教师	组织实验任务并复核报告	实验任务管理、报告上传、批量导入、发起查重、查看结果、统计分析、CSV 导出
学生	查看任务并提交报告	查看实验任务、上传本人报告、查看提交状态

表 3-1 用户角色与功能需求

模块	需求说明	实现状态
登录认证	用户名密码登录，生成 JWT，识别用户角色	已实现
用户与班级管理	维护用户、课程、班级及班级学生分配	已实现
实验任务管理	教师创建、编辑、删除和查看实验任务	已实现
报告上传解析	支持 txt、docx、pdf，支持批量上传和文本解析	已实现
查重计算	同一任务下报告两两比较，生成相似度和风险等级	已实现
结果展示	展示查重结果、相似句子、风险等级和统计图表	已实现
结果导出	导出 CSV 查重结果文件	已实现

表 3-2 系统功能需求

4 系统总体设计

4.1 系统架构设计

系统采用前后端分离架构。前端基于 Vue 3 构建后台管理页面，通过 Axios 调用后端接口；后端基于 Spring Boot 提供 REST API，并通过 MyBatis-Plus 访问 MySQL 数据库；报告文件保存到本地 uploads 目录；查重算法模块在后端服务中完成文本预处理、相似度计算和结果入库。




图 4-1 系统总体架构图

4.2 功能结构设计

系统功能围绕三类用户展开。管理员侧重基础数据维护，教师侧重实验任务与查重分析，学生侧重任务查看和报告提交。核心算法和数据模块为各业务功能提供支撑。




图 4-2 系统功能结构图

4.3 业务流程设计

教师端业务流程是系统的核心流程。教师登录后创建实验任务，学生或教师上传报告，系统解析报告文本并记录字数和句子数。教师发起查重任务后，系统对同一任务下所有解析成功报告进行两两比较，保存查重结果和相似句子，最后在前端展示风险等级和统计图表。

教师端查重业务流程

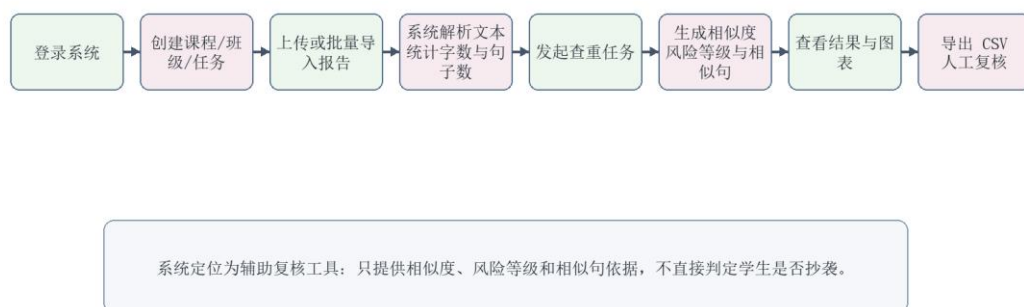


图 4-3 教师端查重业务流程图

4.4 项目目录结构设计

目录	说明
backend	Spring Boot 后端项目，包含控制器、服务、实体、Mapper、算法和工具类
frontend	Vue 3 前端项目，包含页面视图、接口封装、路由和样式
database	MySQL 初始化脚本和演示数据
docs	接口文档、部署说明、演示说明和课程设计报告
samples	用于批量上传和查重演示的样例报告

表 4-1 项目目录结构

5 数据库设计

5.1 数据库设计原则

数据库设计围绕实验报告查重业务展开，遵循实体清晰、关系明确和便于扩展的原则。系统使用 MySQL 作为数据存储，主要保存用户、角色、

课程、班级、实验任务、报告文件、查重任务、查重结果和相似句子等信息。

其中，`report_file` 表保存上传报告的文件信息、解析文本、字数和解析状态；`check_task` 表保存一次查重任务的执行状态和报告数量；`check_result` 表保存两份报告之间的余弦相似度、SimHash 相似度、综合相似度和风险等级；`similar_sentence` 表保存结果详情中的相似句子。

数据库核心 ER 关系简图




图 5-1 数据库核心 ER 关系简图

5.2 核心数据表设计

数据表	主要字段	作用
sys_role	id, role_code, role_name	保存管理员、教师、学生等角色信息
sys_user	id, username, password, real_name, role_id, student_no, teacher_no	保存系统用户信息
course	id, course_name, course_code, teacher_id	保存课程信息及任课教师
class_info	id, class_name, grade, major	保存班级信息
student_class	id, student_id, class_id	保存学生与班级关联
experiment_task	id, course_id, class_id, title, deadline, status	保存实验任务信息
report_file	id, task_id, student_id, parsed_text, parse_status, word_count	保存上传报告和解析文本
check_task	id, experiment_task_id,	保存查重任务信息

	algorithm, report_count, status	
check_result	id, check_task_id, source_report_id, target_report_id, final_similarity, risk_level	保存两两查重结果
similar_sentence	id, check_result_id, source_sentence, target_sentence, sentence_similarity	保存相似句子详情

表 5-1 核心数据表说明

5.3 演示数据设计

为保证系统能够真实演示，初始化脚本内置了多班级、多学生和多实验任务数据。执行 database/init.sql 后，系统会生成 1 个管理员、2 个教师、8 个学生、3 个班级、3 门课程和 4 个实验任务。样例报告按学生姓名或学号命名，教师端批量上传时可以自动匹配学生。

6 查重算法设计与实现

6.1 文本解析与预处理

系统支持 txt、docx 和 pdf 三类常见实验报告格式。txt 文件优先按 UTF-8 编码读取，失败时兼容 GBK 编码；docx 文件通过 Apache POI 提取段落文本；pdf 文件通过 PDFBox 提取普通文本内容。解析后的文本保存到 report_file 表中，供后续查重任务使用。

文本预处理包括文本清洗、大小写统一、去除非中文英文数字字符、轻量级中文二元词条切分和停用词过滤。由于课程设计周期和部署成本限制，系统没有接入复杂中文分词模型，而是采用二元词条切分方法将连续中文文本转换为相邻二字词项。该方法实现简单、计算成本较低，适合实验报告近重复检测。

6.2 TF-IDF 与余弦相似度计算

系统以同一实验任务下所有解析成功的报告作为语料集合，统计词项在不同报告中的文档频率，并计算 IDF 权重。对于每一份报告，系统根据词频和 IDF 构建文本向量。这样可以避免只在两份文本之间临时计算 IDF，使算法流程更符合开题报告中“基于同一任务报告集合建模”的设计思路。

$TF(t,d) = \text{词项 } t \text{ 在报告 } d \text{ 中出现次数} / \text{报告 } d \text{ 的词项总数}$

$IDF(t) = \ln((N+1)/(DF(t)+1))+1$

$Cosine(A,B) = (A \cdot B) / (\|A\| \times \|B\|)$

6.3 SimHash 文本指纹计算

SimHash 将文本特征映射为固定长度的指纹。系统对每个词项生成稳定哈希值，再根据词项频率对 64 位向量进行加权累加。向量中每一位大于 0 则置为 1，否则置为 0，最终得到文本指纹。两个文本指纹的汉明距离越小，说明文本整体特征越接近。

在本系统中，SimHash 相似度计算公式为 $1 - \text{汉明距离} / 64$ 。为避免空文本产生误判，系统对空文本进行了保护处理：当任一文本没有有效词项时，SimHash 相似度直接返回 0。

6.4 综合相似度与风险等级

系统将余弦相似度和 SimHash 相似度进行加权融合，其中余弦相似度权重为 0.7，SimHash 相似度权重为 0.3。该设计使系统既关注词项向量层面的重合程度，也关注整体文本指纹的近重复程度。

$FinalScore = 0.7 \times CosineSimilarity + 0.3 \times SimHashSimilarity$

综合相似度	风险等级	说明
≥ 0.80	高风险	文本高度相似，需要教师重点复核
0.60 - 0.80	中风险	存在明显相似内容，建议查看相似句
0.40 - 0.60	低风险	存在一定重合，需结合任务模板判断
< 0.40	正常	未发现明显重复风险

表 6-1 风险等级划分规则

查重算法流程




图 6-1 查重算法流程图

7 系统功能实现

7.1 登录认证与权限控制

系统登录模块接收用户名和密码，后端根据 `sys_user` 表查询用户信息并校验用户状态。登录成功后，`JwtUtil` 生成包含用户编号、用户名和角色编码的 `Token`，前端将 `Token` 保存到本地存储，并在后续请求中通过 `Authorization` 请求头发送给后端。

后端通过 `AuthInterceptor` 解析 `Token`，并将当前用户信息保存到 `AuthContext` 中。业务层根据角色判断用户权限。例如学生只能查看和提交自己的报告，不能批量上传报告，也不能查看他人的查重结果。



图 7-1 系统登录界面截图

7.2 首页看板与统计分析

首页看板展示课程数量、实验任务数量、报告数量和查重任务数量等核心指标。统计分析页面通过 ECharts 展示风险等级占比、核心数据统计、相似度区间分布和查重任务趋势，帮助教师从整体上了解当前实验任务的报告重复风险。



图 7-2 首页看板与统计图表截图

7.3 用户、课程与班级管理

管理员端提供用户管理、课程管理、班级管理和班级学生分配功能。用户管理支持新增、编辑、删除和密码重置；课程管理维护课程名称、课程编码和任课教师；班级管理维护年级、专业和班级名称；班级学生分配用于建立学生和班级之间的关联关系。



图 7-3 用户与班级管理界面截图

7.4 实验任务管理

教师可以创建实验任务，设置所属课程、所属班级、任务标题、任务说明和截止时间。系统通过实验任务将报告、查重任务和结果组织起来，

保证查重只在同一实验任务下进行，避免不同任务之间因主题差异导致结果失真。



图 7-4 实验任务管理界面截图

7.5 报告上传与内容检测

报告上传模块支持单文件上传和批量上传。教师端可以选择实验任务和学生上传报告，也可以批量选择多个文件。批量上传时，系统会根据文件名中的学生姓名、用户名或学号自动匹配学生。学生端只能提交自己的报告。

上传后系统会完成文件类型、文件大小、任务状态、学生身份、文本提取、字数统计和句子数量统计等检测。若文本过短或句子数量过少，系统会在解析状态中给出“建议教师复核”的提示。



图 7-5 报告上传与解析状态截图

7.6 查重任务与结果展示

教师选择实验任务后可以发起查重任务。后端查询该任务下所有解析成功的报告，如果报告数量少于两份，则提示无法查重。符合条件时，系

统创建 `check_task` 记录，并对报告进行两两比较，生成 `check_result` 和 `similar_sentence` 数据。

查重结果列表按照综合相似度降序展示，教师可以查看报告 A、报告 B、余弦相似度、SimHash 相似度、综合相似度和风险等级。点击详情后，系统展示相似句子列表，便于教师复核具体相似内容。

系统截图占位
请后续替换为实际运行界面截图

图7-6 查重结果列表截图

图 7-6 查重结果列表截图

系统截图占位
请后续替换为实际运行界面截图

图7-7 相似句子详情截图

图 7-7 相似句子详情截图

7.7 结果导出与演示数据

系统支持将查重结果导出为 CSV 文件，导出内容包括结果编号、查重任务编号、报告 A 学生、报告 A 文件、报告 B 学生、报告 B 文件、余弦相似度、SimHash 相似度、综合相似度、风险等级和创建时间。系统还提供多班级、多学生、多任务样例数据，以及 `demo-task1`、`demo-task2` 和 `demo-task3` 三组样例报告，用于答辩演示。

8 系统测试与结果分析

8.1 测试环境

项目	环境
操作系统	Windows
后端环境	JDK 17、Maven 3.9.x、Spring Boot 3.3.7
前端环境	Node.js、Vue 3、Vite、Element Plus、ECharts
数据库	MySQL 8.0
测试工具	Maven Test、Vite Build、浏览器手工测试

表 8-1 测试环境

8.2 功能测试

编号	测试内容	预期结果	测试结果
TC-001	用户登录	正确账号登录成功并返回 Token	通过
TC-002	角色菜单	不同角色显示不同功能菜单	通过
TC-003	课程管理	课程新增、编辑、删除正常	通过
TC-004	班级学生分配	学生可加入指定班级	通过
TC-005	实验任务管理	教师可创建并维护实验任务	通过
TC-006	报告上传	txt、docx、pdf 可上传并解析	通过
TC-007	批量上传	文件名包含姓名或学号时自动匹配学生	通过
TC-008	查重任务	同一任务下多份报告可生成两两查重结果	通过
TC-009	结果详情	可查看相似句子	通过
TC-010	结果导出	可导出 CSV 文件	通过

表 8-2 功能测试用例

8.3 算法与工具类测试

后端新增了 SimilarityCalculatorTest 和 TextExtractUtilTest，用于验证核心算法和文本解析工具。测试覆盖完全相同文本、不相关文本、空文本、

风险等级阈值、相似句匹配、UTF-8 文本解析、GBK 文本解析和不支持文件类型异常。

测试类	测试重点	结果
SimilarityCalculatorTest	相似度计算、空文本处理、风险等级、相似句匹配	通过
TextExtractUtilTest	UTF-8/GBK txt 解析和异常处理	通过
ReportCheckApplicationTests	Spring Boot 上下文启动	通过

表 8-3 自动化测试结果

8.4 构建验证

后端执行 `mvn test` 后，测试数为 9，Failures 为 0，Errors 为 0，构建成功。前端执行 `npm run build` 后，Vite 构建成功，生成 `dist` 目录。构建过程中存在 `chunk` 较大的提示，主要由 Element Plus 和 ECharts 等依赖集中打包造成，不影响系统运行和答辩演示。

系统主流程经验证可以完成登录、查看任务、上传报告、文本解析、发起查重、查看结果、查看相似句、统计分析和导出 CSV 等操作，满足课程设计终稿要求。

9 总结与展望

9.1 总结

本文设计并实现了一套面向高校实验教学场景的实验报告智能查重与分析系统。系统采用 Spring Boot、Vue 3 和 MySQL 技术栈，围绕课程、班级、实验任务、报告文件和查重结果建立业务模型，完成了管理员、教师和学生三类角色的主要功能。系统支持 txt、docx 和 pdf 报告上传与文本解析，支持教师批量上传报告并自动匹配学生，能够对同一实验任务下的报告进行两两相似度计算，并展示综合相似度、风险等级和相似句子。

在算法方面，系统采用基于 TF-IDF 思想的文本向量化方法，结合余弦相似度和 SimHash 文本指纹计算综合相似度。系统以同一实验任务下所有已解析报告作为语料集合计算 IDF，使算法流程与开题报告中的设计目

标保持一致。测试结果表明，系统能够支撑完整演示流程，具有较好的实用性和可解释性。

9.2 不足与展望

受课程设计周期限制，系统仍存在一些可以继续完善的地方。第一，当前中文处理采用轻量级二元词条切分，不具备成熟中文分词和深度语义理解能力，后续可以接入 Jieba、HanLP 或基于向量模型的语义相似度算法。第二，当前密码为基础明文存储方式，后续可以引入 BCrypt 提升认证安全性。第三，查重报告当前支持 CSV 导出，后续可以增加 Word 或 PDF 详情报告导出。第四，前端页面主要集中在一个 DashboardView 中，后续可以拆分为独立路由页面，提高代码可维护性。第五，可以继续增加操作日志、历史报告库查重和跨任务查重等功能。

总体而言，本系统已经完成开题报告中提出的核心目标，能够作为课程设计成果进行演示和答辩。系统定位为辅助教师复核实验报告的轻量级工具，后续可在算法精度、安全性、工程结构和产品化体验方面继续优化。

致 谢

在本次计算机综合课程设计过程中，我围绕实验报告查重这一教学场景完成了需求分析、系统设计、数据库建模、前后端开发、查重算法实现、测试验证和文档整理等工作。通过该项目，我进一步理解了 Web 系统开发流程，也加深了对文本相似度算法和工程实践的认识。

感谢指导教师在课程设计选题、技术路线和报告撰写方面给予的指导，也感谢课程学习过程中提供帮助的同学和相关开源技术社区。正是这些支持使我能够较为完整地完成本系统设计与实现。由于个人能力和时间有限，系统仍存在不足，后续将继续从算法效果、系统安全性和用户体验等方面进行完善。

参考文献

- [1] Salton G, Buckley C. Term-weighting approaches in automatic text retrieval[J]. Information Processing & Management, 1988, 24(5): 513-523.
- [2] Manku G S, Jain A, Das Sarma A. Detecting near-duplicates for web crawling[C]. Proceedings of the 16th International Conference on World Wide Web, 2007: 141-150.

- [3] 李智慧. Spring Boot 企业级开发教程[M]. 北京: 人民邮电出版社, 2021.
- [4] 尤雨溪. Vue.js 设计与实现[M]. 北京: 人民邮电出版社, 2022.
- [5] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- [6] 宗成庆. 统计自然语言处理[M]. 北京: 清华大学出版社, 2013.
- [7] Halim J, Lasut D. Document Plagiarism Detection Application Using Web-Based TF-IDF and Cosine Similarity Methods[J]. bit-Tech, 2024, 7(2): 202-213.
- [8] Li Z, Zhu J, Cheng X, Lu Q. Optimized Algorithm Design for Text Similarity Detection Based on Artificial Intelligence and Natural Language Processing[J]. Procedia Computer Science, 2023, 228: 195-202.
- [9] Yuan L, Gao S, Pan P. CTSARF: A Chinese Text Similarity Analysis Model based on Residual Fusion[J]. Neurocomputing, 2023, 559: 126801.
- [10] Saeed S, Rajput Q, Haider S. SUMEX: A hybrid framework for Semantic textUal siMilarity and EXplanation generation[J]. Information Processing & Management, 2024, 61(5): 103771.
- [11] Apache Software Foundation. Apache POI Documentation[EB/OL]. <https://poi.apache.org/>.
- [12] MyBatis-Plus Team. MyBatis-Plus Documentation[EB/OL]. <https://baomidou.com/>.

附 件

附件 A 系统运行与演示说明

系统源码位于 report-check-system 目录。后端启动命令为 cd backend 后执行 mvn spring-boot:run；前端启动命令为 cd frontend 后执行 npm run dev。项目根目录提供 start-dev.ps1 和 stop-dev.ps1，用于 Windows 环境下一键启动和停止服务。

附件 B 样例报告与测试数据

样例报告位于 samples 目录，其中 demo-task1、demo-task2 和 demo-task3 可用于教师端批量上传演示。初始化数据库脚本 database/init.sql 包含 3 个班级、3 门课程、4 个实验任务和 8 个学生账号。

附件 C 主要代码文件

文件	说明
SimilarityCalculator.java	文本预处理、TF-IDF 余弦相似度、SimHash 和风险等级计算
CheckTaskService.java	发起查重任务并生成两两比较结果
ReportFileService.java	报告上传、文本解析、内容检测和批量上传

TextExtractUtil.java	txt、docx、pdf 文本提取工具
DashboardView.vue	前端后台管理主界面
database/init.sql	数据库建表语句和初始化演示数据

表 C-1 主要代码文件说明